Reconnaissance d'expressions faciales

Du CNN entraîné sur FER-2013 à la détection en direct par webcam

Fatima Aguel · Nicolas Wujczak

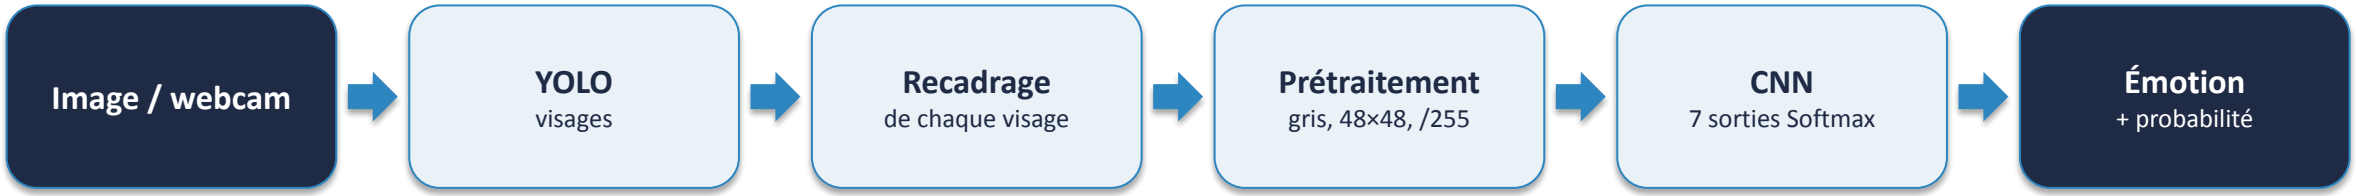
Objectif et démarche

- 7 émotions : colère, dégoût, peur, joie, tristesse, surprise, neutre
- Classification multiclasse
  – 7 neurones de sortie + Softmax ⟶ une probabilité par émotion
  – classe prédite = probabilité maximale (argmax)

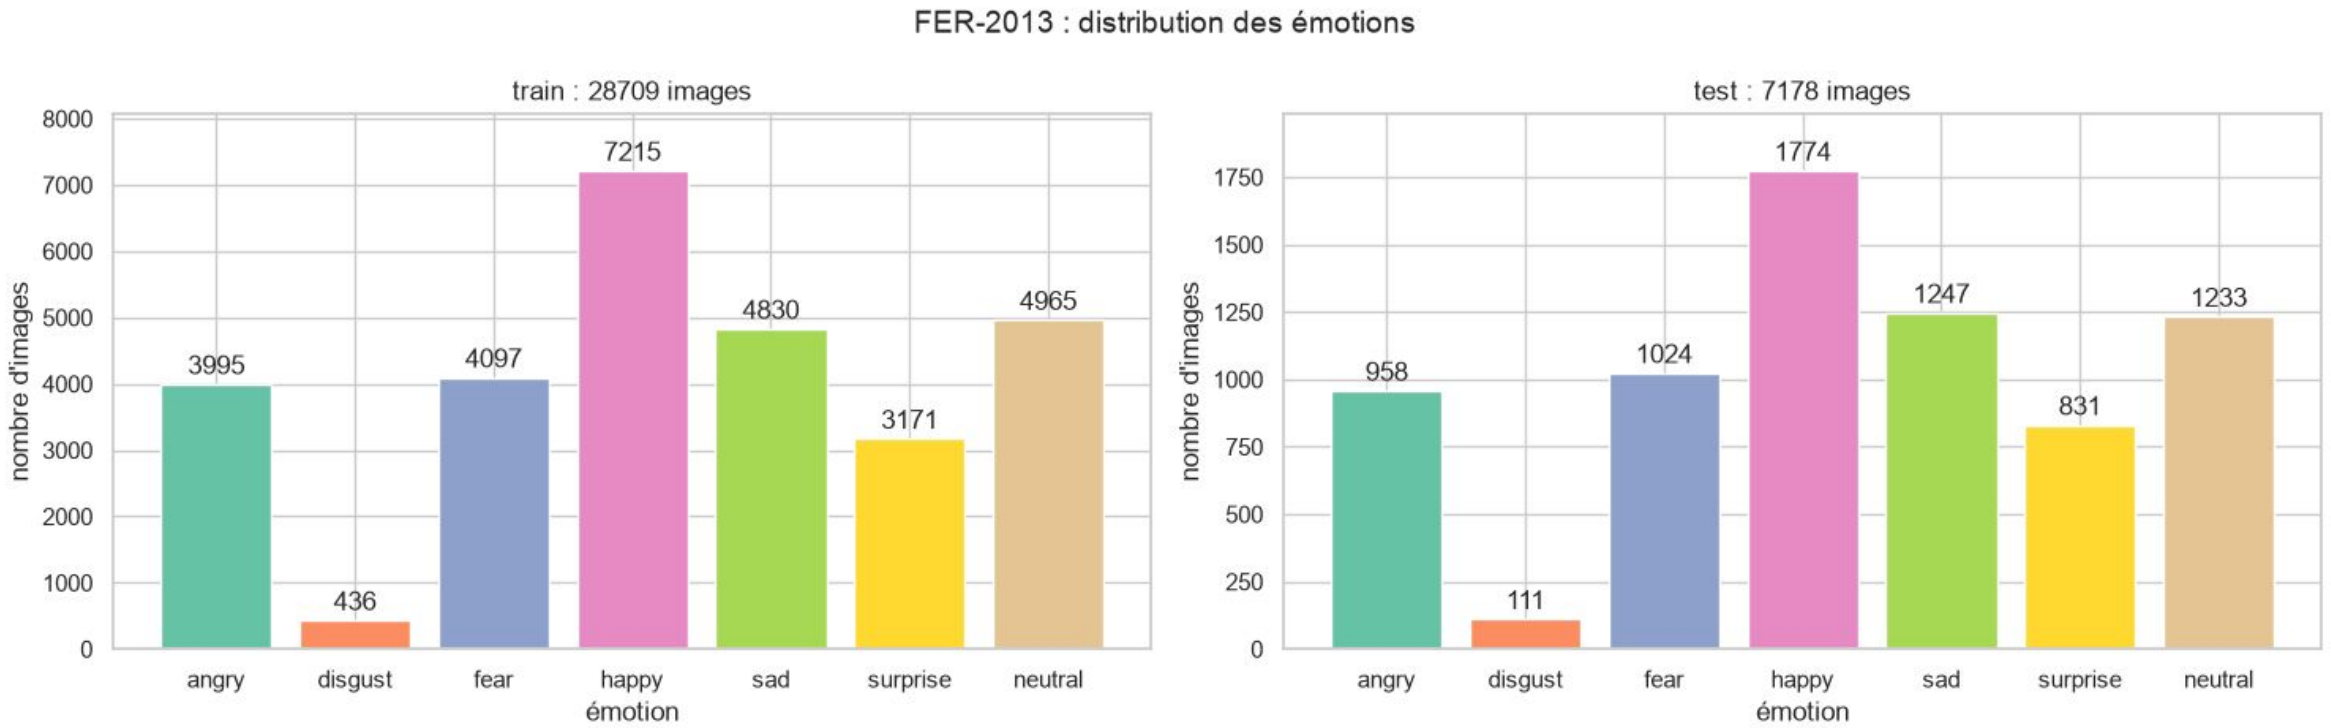
- **Démarche progressive**

1. MLP de référence
2. CNN avec Keras
3. Entraînement et analyse des erreurs
4. Expériences d'amélioration
5. Détection des visages (YOLO) + webcam

Pipeline final



Données : FER-2013



- 35 887 visages 48×48, niveaux de gris (ICML 2013, Kaggle)
- Labels bruités : précision humaine ≈ 65 %
- Déséquilibre : joie 25 %, dégoût 1,5 % (×16,5)

- Train 28 709 (80 %) / test 7 178 (20 %)
- Validation : 20 % du train, stratifiée
- **Final : 64 % train · 16 % validation · 20 % test**

Préparation des données

- **Une seule fonction : preprocess_face**
  – niveaux de gris → 48×48 → pixels / 255 → forme (48, 48, 1)
  – même fonction à l'entraînement et sur la webcam
- Normalisation [0, 1] : gradients stables
- Labels entiers 0–6 + sparse_categorical_crossentropy
  – équivalent au one-hot, plus léger
- Test jamais utilisé pour régler le modèle
- Poids de classe (train uniquement)
  – dégoût 9,4 · joie 0,57

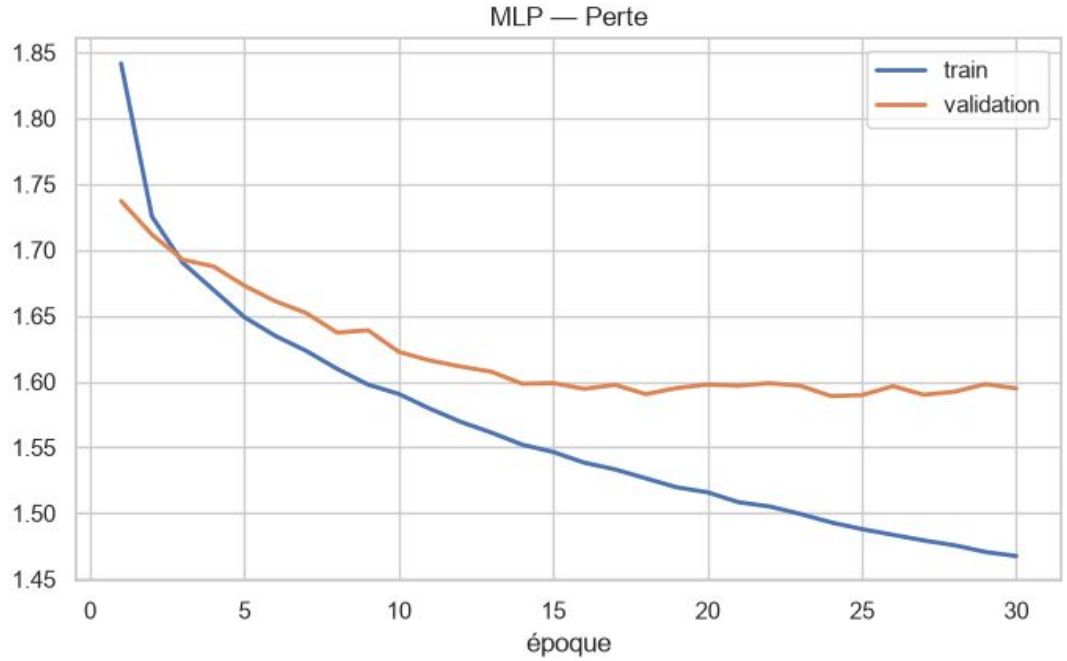


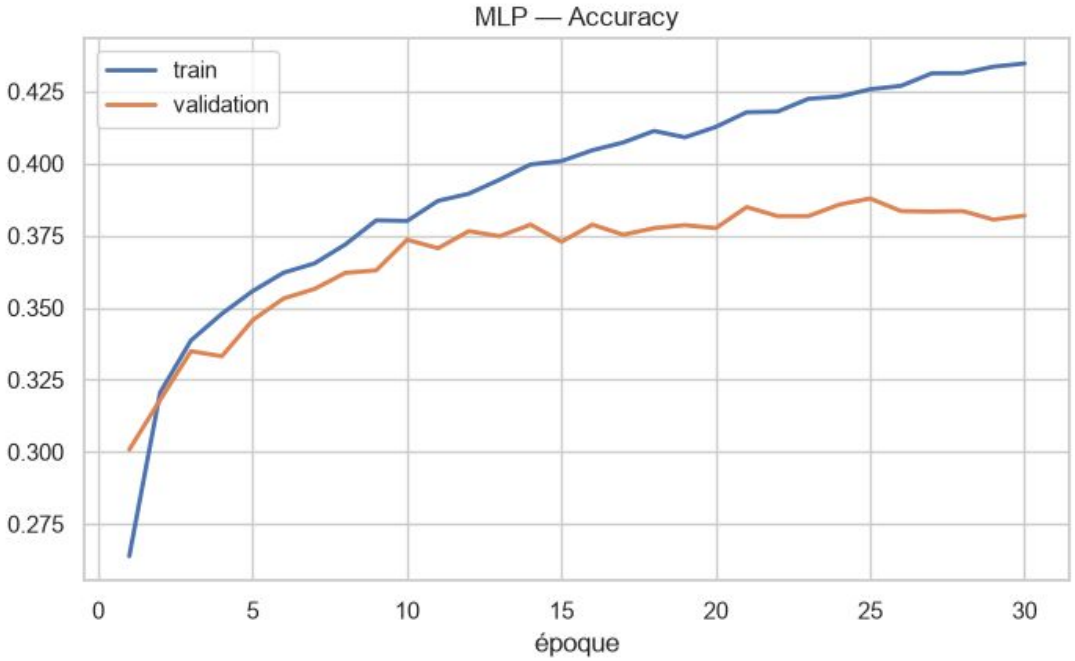
Modèle de référence : MLP

48×48 ⟶ Flatten (2 304) ⟶ Dense 256 + ReLU ⟶ Dense 7 + Softmax · 591 879 paramètres

- **Accuracy validation : 38,2 %**
  – hasard 14,3 % · toujours « joie » 25,1 %
- Surapprentissage dès ~15 époques

- **Limite : l'aplatissement perd la structure 2D**
  – 99,7 % des poids dans la 1re couche
  – ⟶ motivation pour le CNN





CNN : architecture

Couche	Sortie	Paramètres
Conv 3×3, 32 + ReLU	48×48×32	320
MaxPool 2×2	24×24×32	0
Conv 3×3, 64 + ReLU	24×24×64	18 496
MaxPool 2×2	12×12×64	0
Conv 3×3, 128 + ReLU	12×12×128	73 856
MaxPool 2×2	6×6×128	0
Flatten	4 608	0
Dense 64 + ReLU	64	294 976
Dense 7 + Softmax	7	455

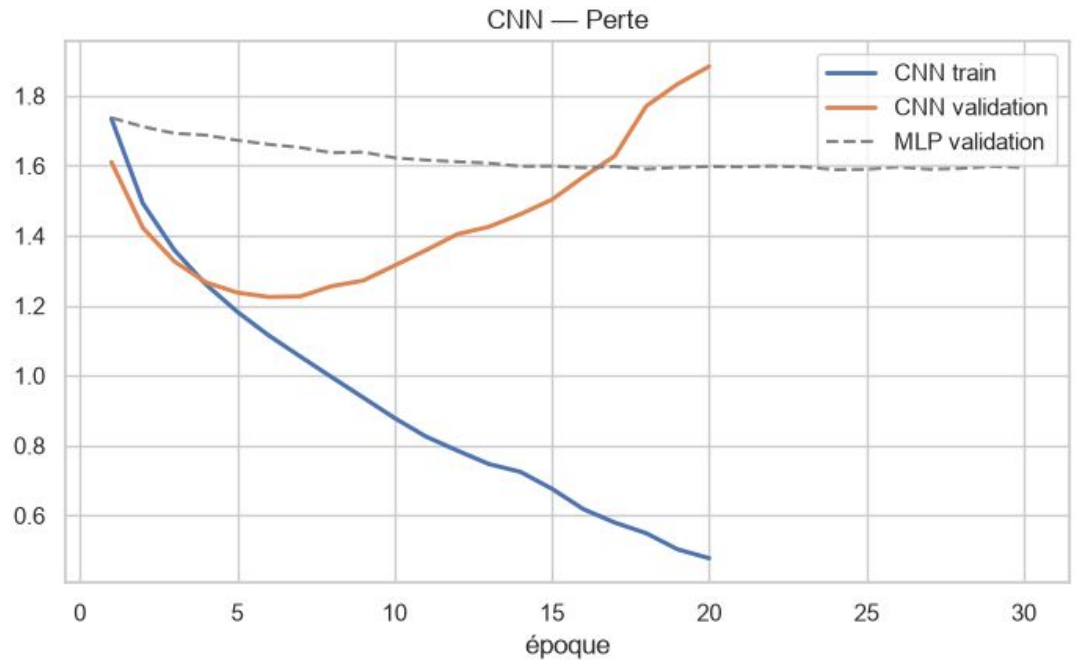
- **388 103 paramètres (MLP : 591 879)**
- Kernel 3×3, stride 1, padding same
  – seul le pooling réduit la taille
- Filtres 32 → 64 → 128
  – bords, puis motifs plus complexes
- Convolutions : 24 % des poids
  – un filtre partagé par toutes les positions

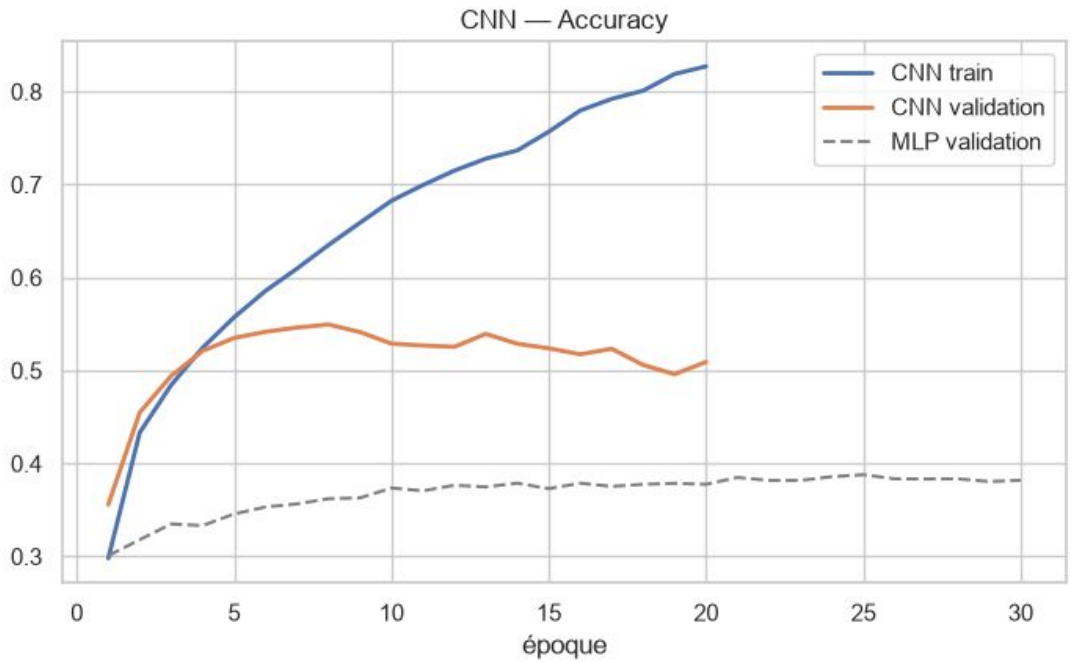


Entraînement du CNN

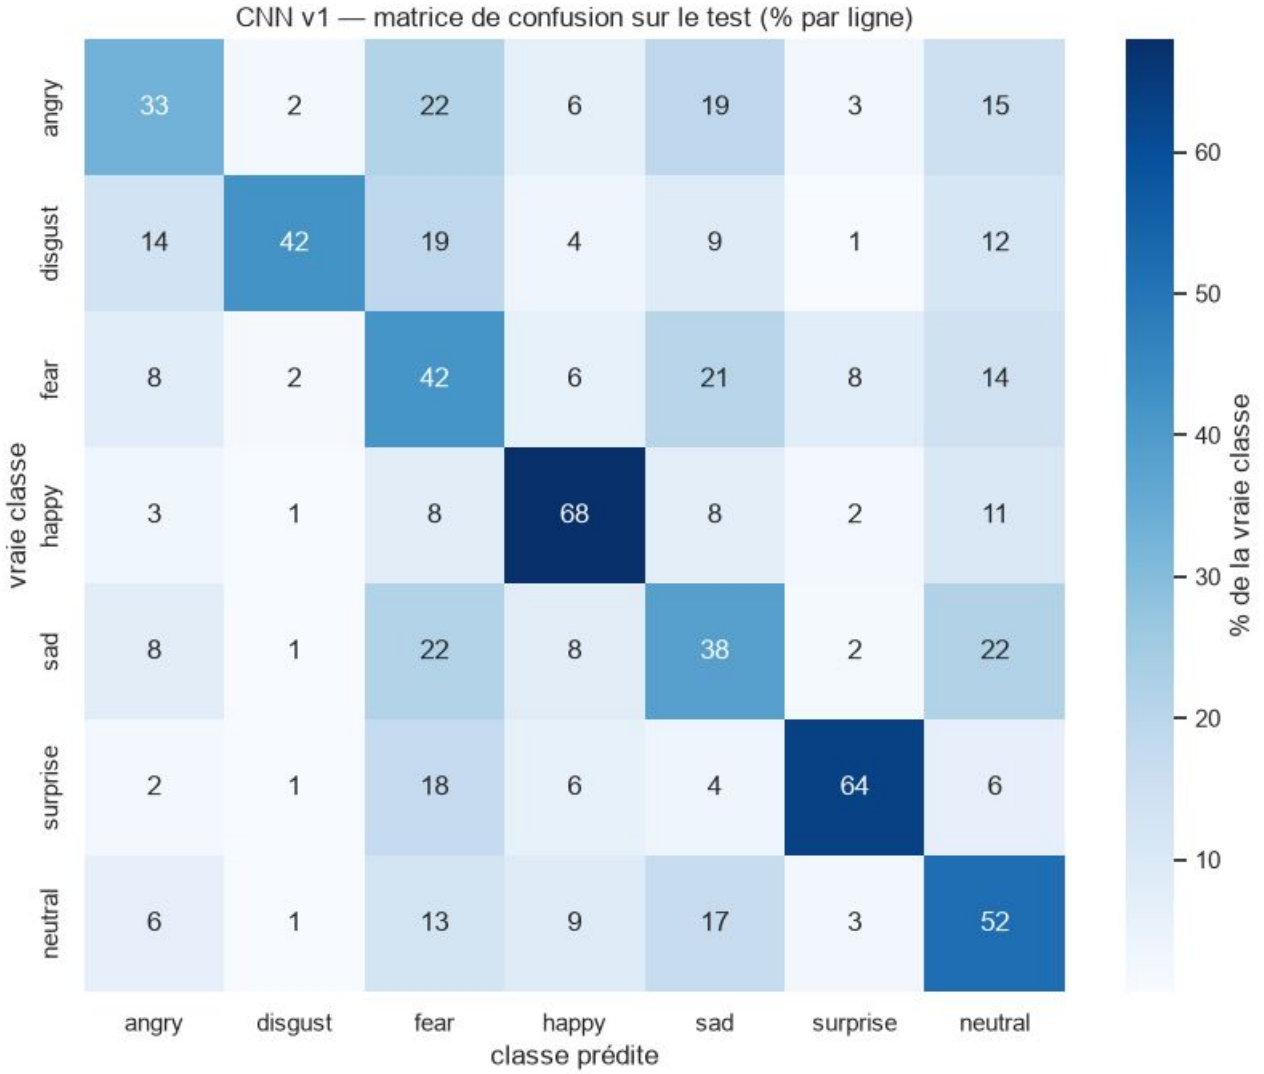
Choix	Valeur	Pourquoi
Perte	sparse cat. crossentropy	7 classes, Softmax, labels entiers
Optimiseur	Adam, lr 0,001	pas adaptatif, valeur standard
Batch / époques	128 / 20	mêmes réglages que le MLP
Métrique	accuracy	+ métriques par classe ensuite

- **Meilleure validation : 54,9 % (époque 8)**
  – MLP : 38,8 %
- Surapprentissage : train 83 %, val 51 % à l'époque 20





Évaluation sur le test (CNN v1)

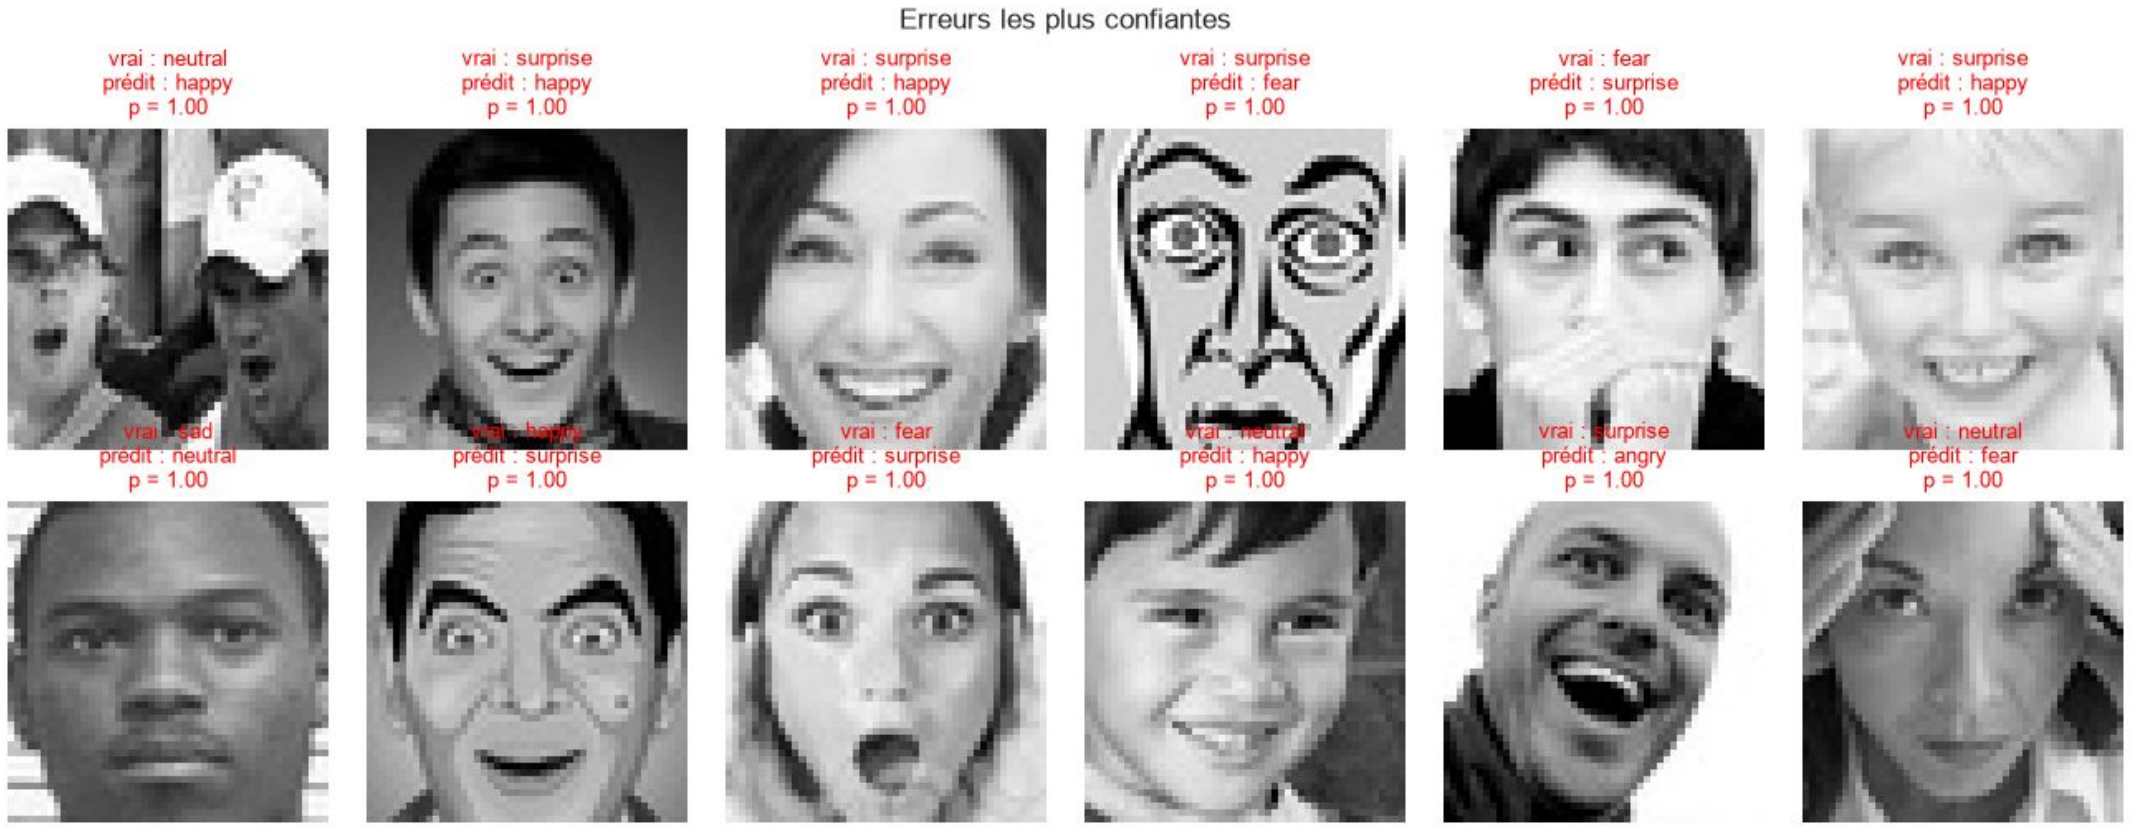


Accuracy test : 50,8 %

Émotion	Précision	Rappel	F1
joie	0,76	0,68	0,72
surprise	0,72	0,64	0,68
neutre	0,44	0,52	0,48
dégoût	0,39	0,42	0,41
colère	0,48	0,33	0,39
tristesse	0,38	0,38	0,38
peur	0,31	0,42	0,36

- **Confusions principales**
  - tristesse ⟶ neutre 22 %, ⟶ peur 22 %
  - colère ⟶ peur 22 %
  - peur ⟶ tristesse 21 %

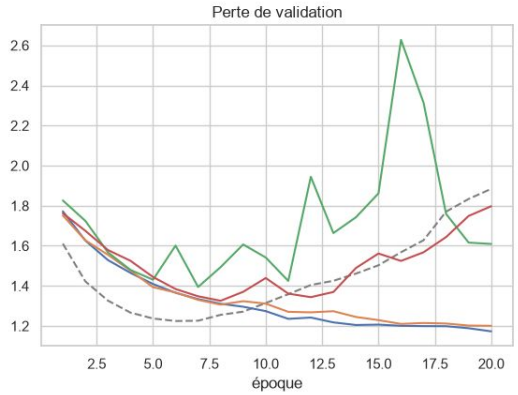
Analyse des erreurs

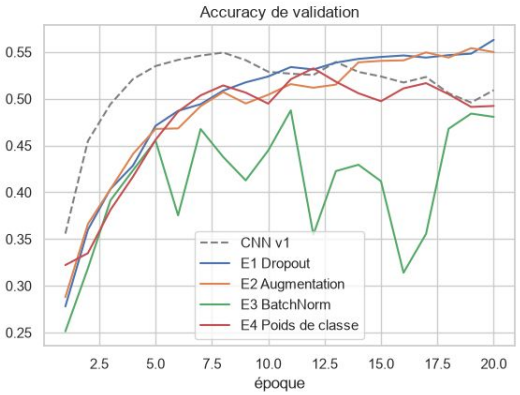


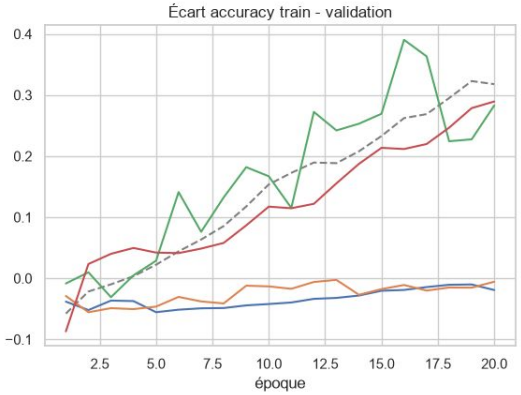
- Expressions proches : peur / surprise, tristesse / neutre
- Labels bruités (annotation semi-automatique)
- 48×48 : détails fins perdus
- Profils, mains, filigranes

Expériences (comparaison sur la validation)

Expérience	Modification	Meilleure val acc	Écart train − val	F1 macro	Rappel dégoût
CNN v1	référence	54,9 %	+31,8 pts	0,49	40 %
E1	**Dropout 0,25 / 0,5**	**56,3 %**	**−1,9 pts**	**0,46**	**1 %**
E2	Data augmentation	55,4 %	−0,6 pts	0,47	7 %
E3	BatchNormalization	48,8 %	+28,3 pts	0,40	0 %
E4	Poids de classe	53,3 %	+28,9 pts	0,48	37 %

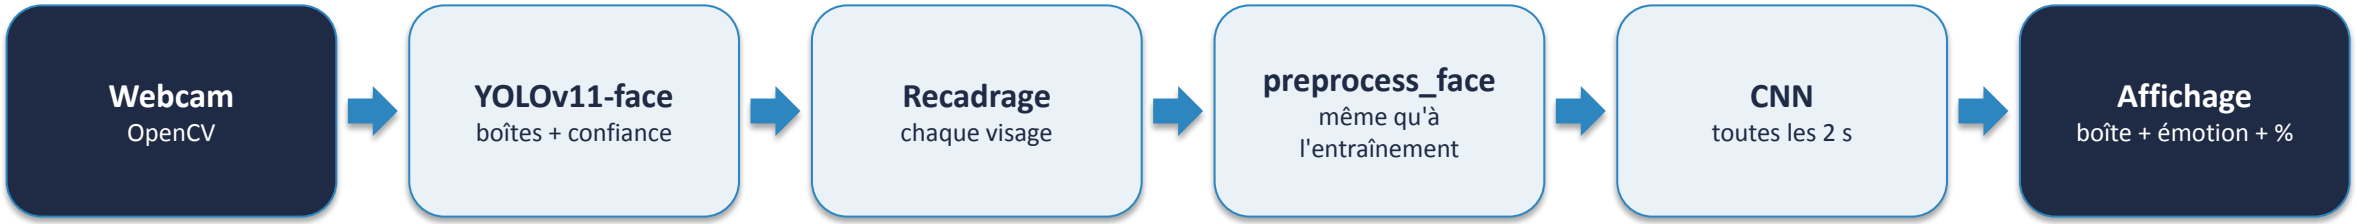






- Dropout et augmentation suppriment le surapprentissage
- BatchNorm : moins bien ici
- Compromis : dégoût oublié sans poids de classe
- **Suite : combiner les trois**

Démonstration : détection en direct



- **Détecteur : YOLOv11 pré-entraîné sur des visages**
  – un YOLO COCO ne détecte que des personnes
- Bounding box + score de confiance
- NMS : supprime les boîtes qui se recouvrent (IoU)
- Plusieurs visages traités en un seul batch

Démo en direct

python app.py

Bilan et perspectives

Bilan

- CNN : +16 pts sur le MLP en validation, avec moins de paramètres
- Test : 50,8 % (humain ≈ 65 %)
- Joie, surprise : bien reconnues
- Peur, tristesse, colère : confondues
- Dropout et augmentation corrigent le surapprentissage
- Pipeline complet : YOLO + CNN sur webcam

Perspectives

- Combiner Dropout + augmentation + poids de classe
- Early Stopping, plus d'époques
- Choisir le modèle final sur la validation
  – puis une seule évaluation sur le test
- Transfer learning (réseau pré-entraîné)
- Mettre le modèle final dans l'application